

Descripción:

En este módulo no se tienen tareas perse, sino avances de los portafolios. El esquema de evaluación es basado en retroalimentación continua, por ello se tienen 2 entregas: una después de ver el tema donde el estudiante entrega su primer intento y se le da retroalimentación y una al final del bloque donde el estudiante puede entregar las correcciones de su entrega anterior y se le califica.

✓ Instrucciones:

Entregable: Implementación de una técnica de aprendizaje máquina sin el uso de un framework.

Selecciona uno de los dos primeros 'Challenge' vistos en clase (Week01_Challenge.pdf o Week02_Challenge1.pdf) y programa un algoritmo que permita resolver el problema. Dicho algoritmo debe ser uno de los algoritmos vistos en el módulo (o que tu profesor de módulo autorice), y no puedes usar ninguna biblioteca o framework de aprendizaje máquina, ni de estadística avanzada. Lo que se busca es que implementes manualmente el algoritmo, no que importes un algoritmo ya implementado. Divide el set de datos del problema en dos subconjuntos, uno para entrenamiento y otro para prueba. Entrena tu modelo sobre el primer subconjunto, y por un mínimo de 100 iteraciones. Selecciona valores para la tasa de aprendizaje y para los parámetros iniciales, según tu criterio. Prueba tu implementación. Para ello, utiliza el modelo entrenado para hacer predecir las salidas del subconjunto de prueba, y compara contra los datos reales en una gráfica. Calcula el valor de la función de costo para el subconjunto de entrenamiento, y para el subconjunto de prueba. Para facilitar la revisión, entrega dos archivos. El primero debe ser un Jupyter Notebook con todo el desarrollo (código comentado). El segundo debe ser un PDF del Jupyter Notebook. Para esto último, utiliza el comando nbconvert --to html para exportar el notebook a HTML y poder guardar el PDF más fácilmente (<https://github.com/jupyter/nbconvert>). Ten en cuenta que debes cargar tu directorio de Drive y dar la ruta al archivo, por lo que el comando completo sería: !jupyter nbconvert --to html [/content/drive/MyDrive/ColabNotebooks/archivo.ipynb](#) Después de la entrega intermedia se te darán correcciones que puedes incluir en tu entrega final.

- Elemento de la lista
- Elemento de la lista

Para este entregable se escogio el Challenge del week_02_Challenge1

Attendance	Homework	Pass	Reference
80	75	yes	yes
65	70	no	no
95	85	yes	yes
95	100	yes	no
85	65	no	no
75	55	no	no
90	90	yes	yes
65	80	yes	no

✓ Librerías

Se importan las librerías necesarias **texto en negrita**

```
1 import numpy as np
2 from sklearn.model_selection import train_test_split
3 import matplotlib.pyplot as plt
```

✓ Función de regresión logística, de costo y de hipotesis

se presenta una función de costo para actualizar los valores de θ_0 y θ_1

```
1 def log_loss(y_true, y_pred):
2     # Evitar el logaritmo de cero agregando un pequeño valor epsilon.
3     epsilon = 1e-15
4     y_pred = np.clip(y_pred, epsilon, 1 - epsilon)
5
6     # Cálculo del log-loss
7     cost = -np.mean(y_true * np.log(y_pred) + (1 - y_true) * np.log(1 - y_pred))
8     return cost
9
10
11
```

```

12 # Crear función lambda para la función de hipótesis
13 f = lambda th0 , th1, x : 1 / (1 + np.exp(-1*(th0+th1*x)))
14
15
16
17 def logistic_reg(iterations, th0, th1, alfa, x_arr, y_arr):
18     n = x_arr.size
19     delta0 = np.zeros(n)
20     delta1 = np.zeros(n)
21     cost_history = []
22
23     for _ in range(iterations):
24
25         # en cada iteración se calcula con los parametros correspondien
26         y_pred = np.array([f(th0, th1, x) for x in x_arr])
27
28
29         for i in range(n):
30             delta0[i] = f(th0, th1, x_arr[i]) - y_arr[i]
31             delta1[i] = (f(th0, th1, x_arr[i]) - y_arr[i])*x_arr[i]
32
33         th0 -= alfa * np.mean(delta0)
34         th1 -= alfa * np.mean(delta1)
35
36         # Calcular y almacenar la función de costo log-loss en cada ite
37         cost = log_loss(y_arr, y_pred)
38         cost_history.append(cost)
39
40     return th0, th1, cost_history

```

✓ Declaracion de variables

se declaran las variables y parametros para entrenar a el modelo.

```

1 #valores de x1
2 attendance = np.array([80,65,95,95,85,75,90,65])
3 #valores de x2
4 homework = np.array([75,70,85,100,65,55,90,80])
5 #valores de y
6 pass_ = np.array([1,0,1,1,0,0,1,1])
7
8
9 #vamos a dividir los datos para su posterior uso:
10

```

```
11 # División de datos
12
13 #division para attendance
14 attendance_train, attendance_test, pass_train_attendance, pass_test_at
15
16 #division para homework
17 homework_train, homework_test, pass_train_homework, pass_test_homework
18
19
```

✓ Selección de parametros

En este caso, los parámetros del modelo se seleccionaron de manera arbitraria, lo que significa que no hubo un proceso estructurado o basado en una lógica estadística o matemática detrás de su elección. Esto implica que no se realizaron análisis previos sobre la influencia de los parámetros en el desempeño del modelo, ni se exploraron de manera exhaustiva técnicas como la validación cruzada, o la búsqueda aleatoria (random search) para encontrar la mejor combinación de hiperparámetros.

```
1 #valores de theta 0 y theta 1 respectivamente
2 parametros = np.array([0.989,0.007], dtype= float)
3 #Valor del hiperparamtro alfa
4 alfa = 0.01
```

✓ Entrenar el modelo

se entrena el modelo insertando las variables y parametros en la función de costo

```
1 #entrenamos el modelo utilizando attendance primero
2
3 attendance_th0, attendance_th1, attendance_cost_history = logistic_reg
4
5
6
7 #entrenamos el modelo utilizando homework despues
8
9 homework_th0, homework_th1, homework_cost_history = logistic_reg(1000,
10
11
```

12
13

```
1 print(attendance_th0, attendance_th1, attendance_cost_history)
2 print(homework_th0, homework_th1, homework_cost_history)
```

```
⇒ 0.22315048847644303 -0.2863802209264763 [0.9297004512870488, 9.096867724263003,
0.29586879410141503 0.26762482696108414 [0.9158749744502155, 6.694333813926097,
```

✓ Cálculo de predicciones

```
1 # Función de hipótesis con los parámetros aprendidos
2 def predict(th0, th1, x):
3     return 1 / (1 + np.exp(-1 * (th0 + th1 * x)))
4
5 # Calcular las predicciones para el conjunto de prueba
6
7 attendance_predictions = predict(attendance_th0, attendance_th1, attendance_test)
8
9 # como devuelve un valor entre 0 y 1 representativo de la probabilidad,
10 # true si es mayor a un umbral de 0.5 y luego convertir dicho valor a booleano
11 attendance_predictions = (attendance_predictions >= 0.5).astype(int)
12
13 homework_predictions = predict(homework_th0, homework_th1, homework_test)
14
15 homework_predictions = (homework_predictions >= 0.5).astype(int)
16
17
```

1 Comienza a programar o generar con IA.


```
1 print(homework_predictions)
2 print(pass_test_homework)
3 print(attendance_predictions)
4 print(pass_test_attendance)
5
6
```

```
⇒ [1 1 1 1]
   [1 0 1 1]
   [0 0 0 0]
   [0 1 1 1]
```

✓ Gráfico de comparación de resultados

primero se hará la gráfica para attendance

```
1 # Graficar probabilidades predichas vs etiquetas reales para 'attendance'
2 plt.figure(figsize=(10, 5))
3 plt.scatter(attendance_test, attendance_predictions, color='blue', label='Predichas')
4 plt.scatter(attendance_test, pass_test_attendance, color='red', marker='x', label='Reales')
5 plt.title('Probabilidades Predichas vs. Etiquetas Reales para Attendance')
6 plt.xlabel('Attendance Scores')
7 plt.ylabel('Probabilidad / Clase Real')
8 plt.legend()
9 plt.grid(True)
10 plt.show()
11
12 # Graficar probabilidades predichas vs etiquetas reales para 'homework'
13 plt.figure(figsize=(10, 5))
14 plt.scatter(homework_test, homework_predictions, color='blue', label='Predichas')
15 plt.scatter(homework_test, pass_test_homework, color='red', marker='x', label='Reales')
16 plt.title('Probabilidades Predichas vs. Etiquetas Reales para Homework')
17 plt.xlabel('Homework Scores')
18 plt.ylabel('Probabilidad / Clase Real')
19 plt.legend()
20 plt.grid(True)
21 plt.show()
22
```



Haz doble clic (o ingresa) para editar

Se tienen que calcular las métricas de desempeño: accuracy, precision, recall y F1.

✓ Cálculo de función de costo para subconjunto de entrenamiento, y para el subconjunto de prueba.

para Attendance:

prueba

```
1 print(log_loss(pass_test_attendance, attendance_predictions))
```

```
⇒ 25.904082296183013
```

entrenamiento

```
1 #como los de prueba tienen un tamaño diferente no se podrá calcular co
2 #aleatoriamente dos elementos del subconjunto
3
4 print(log_loss(pass_train_attendance, attendance_predictions))
```

```
⇒ 17.269388197455342
```

para Homework:

prueba

```
1 print(log_loss(pass_test_homework, homework_predictions))
```

```
⇒ 8.63489399808522
```

entrenamiento

```
1
2 print(log_loss(pass_train_homework, homework_predictions))
```

```
⇒ 17.26978799617044
```


Conclusiones

el modelo no predice con la suficiente exactitud si los estudiantes pasarán dependiendo de su