Momento de Retroalimentación: Módulo 2 Uso de framework o biblioteca de aprendizaje máquina para la implementación de una solucion

Jacobo Hirsch Rodriguez A00829679

Primero nos conectamos a google drive para obtener el dataset

```
from google.colab import drive

drive.mount("/content/gdrive")
!pwd  # show current path
```

```
Drive already mounted at /content/gdrive; to attempt to forcibly remount, call drive.mount("/content/gdrive", force_remount=
/content/gdrive/My Drive/ITESM ITC/Septimo semestre/Datasets
```

ahora vamos a cambiar de directorio para acceder a la carpeta donde se encuentra nuestro dataset. Para este entregable decidí hacer el challenge de valhalla con una solución de regresión lineal

```
%cd "/content/gdrive/MyDrive/ITESM ITC/Septimo semestre/Datasets"
!ls  # show current directory
```

```
/content/gdrive/MyDrive/ITESM ITC/Septimo semestre/Datasets
amazon_product.csv  iris.data  mc-donalds-menu.csv  titanic  Valhalla23.csv  wine.data  wine.names
```

En esta sección vamos a importar todas las librerias que vamos a necesitar

```
import pandas as pd
from sklearn.model_selection import train_test_split #se usa para dividir un conjunto de datos en dos subconj
from sklearn.linear_model import SGDRegressor # implementa un modelo de regresión lineal utilizando un algori
from sklearn.metrics import mean_squared_error #Función para calcular el error cuadrático medio (MSE), una mé
import matplotlib.pyplot as plt #se utiliza para crear visualizaciones de datos en Python.
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LinearRegression
```

Ahora, vamos a cargar el archivo

```
valhalla = pd.read_csv("Valhalla23.csv")
valhalla.head()
```

	Celsius	Valks
0	61.4720	-139.740
1	70.5790	-156.600
2	-7.3013	73.269
3	71.3380	-165.420
4	43.2360	-75.835

dividimos el dataset en sus caracteristicas "x" y "y"

```
X = valhalla[['Celsius']] #dejamos el doble corchete para que se mantenga como un dataframe (en lugar de una
y = valhalla['Valks']
```

Vamos a graficarlo para ver si existe alguna relación entre las dos variables que se pueda observar a simple vista

```
plt.figure(figsize=(10, 6))

plt.scatter(X, y, color='blue', label='Datos Reales')
```

```
4
5 plt.xlabel('Celsius')
6 plt.ylabel('Valks')
7 plt.title('Valores Reales')
8 plt.legend()
9 plt.show()
```

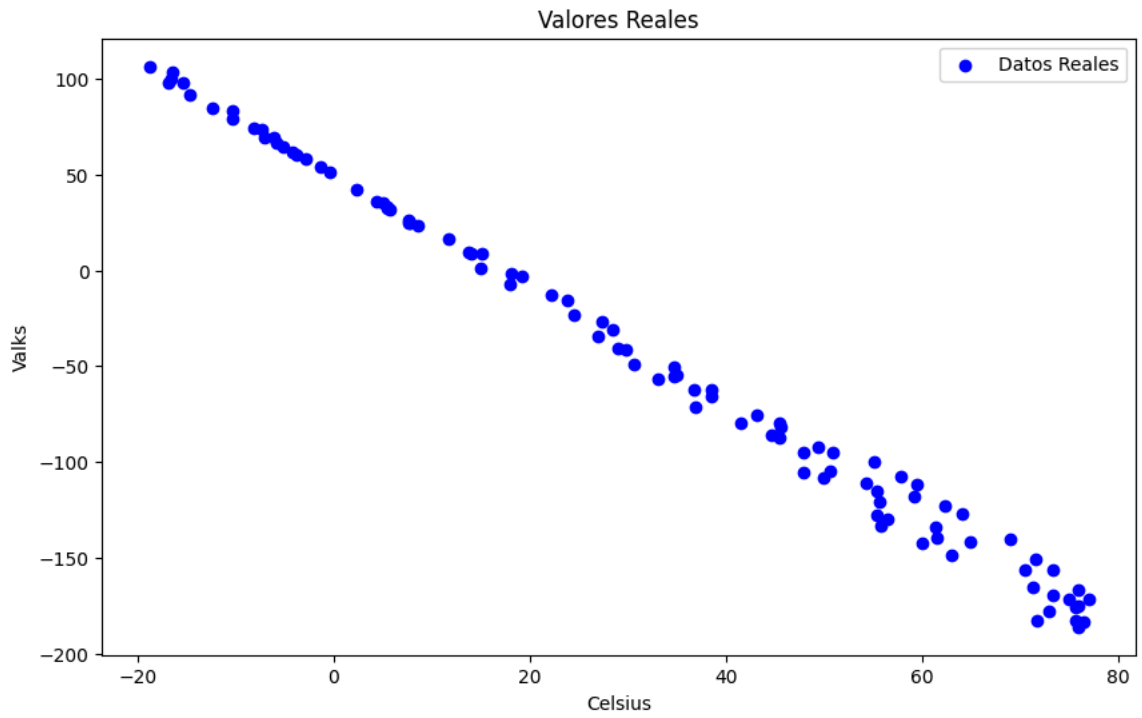

División de datos

dividimos los datos en dos subconjuntos, uno de prueba y otro de entrenamiento. En este caso se configuro para que el 20% de los datos sean de prueba y el 80% restante de entrenamiento. Se utilizo la semilla "42" para garantizar que la división sea reproducible.

```
1 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.5, random_state=42)
```

Escalamiento de datos

hubo problemas utilizando el modelo de regresión SGDR sin escalar los datos por lo que fue necesario escalarlos.

```
1 # Inicializar el escalador
2 scaler = StandardScaler()
3
4 # Ajustar el escalador a los datos de entrenamiento y transformar tanto los datos de entrenamiento como los d
5 X_train_scaled = scaler.fit_transform(X_train)
6 X_test_scaled = scaler.transform(X_test)
7
```

Configuración y entrenamiento

```
1 """model = SGDRegressor(penalty='l2', alpha=0.01, max_iter=100, learning_rate='optimal', random_state=42)
2 model = LinearRegression()
3 model.fit(X_train, y_train)
4 """
5 # Inicializar el modelo con los parámetros elegidos
6 model = SGDRegressor(penalty='l2', alpha=0.001, max_iter=10000, learning_rate='optimal', random_state=42)
7
```

```
# Ajustar el modelo a los datos de entrenamiento escalados
model.fit(X_train_scaled, y_train)


```

```
SGDRegressor(alpha=0.001, learning_rate='optimal', max_iter=10000,
             random_state=42)
```

SGDRegressor: Crea un modelo de regresión lineal que usa descenso de gradiente estocástico. La penalización l2 aplica regularización Ridge, max_iter=100 define que el modelo se entrenará por un máximo de 100 iteraciones, y learning_rate='optimal' ajusta automáticamente la tasa de aprendizaje.

model.fit:Entrena el modelo utilizando el conjunto de entrenamiento (X_train, y_train). El modelo ajusta sus parámetros para minimizar el error en estos datos.

Evaluación del modelo

```

y_train_pred = model.predict(X_train_scaled) #Genera predicciones usando el modelo entrenado para los datos d
y_test_pred = model.predict(X_test_scaled) #Genera predicciones usando el modelo entrenado para los datos de


#alcula el error cuadrático medio (MSE) para el conjunto de entrenamiento,
#comparando las predicciones (y_train_pred) con los valores reales (y_train).
train_mse = mean_squared_error(y_train, y_train_pred)

#Calcula el MSE para el conjunto de prueba, comparando las predicciones (y_test_pred)
#con los valores reales (y_test).
test_mse = mean_squared_error(y_test, y_test_pred)


#imprimimos los resultados de nuestras metricas
print(f"Error Cuadrático Medio en Entrenamiento: {train_mse}")
print(f"Error Cuadrático Medio en Prueba: {test_mse}")

```

```
Error Cuadrático Medio en Entrenamiento: 86.2761597182914
Error Cuadrático Medio en Prueba: 83.28345282977081
```

Visualizacion de resultados

```
plt.figure(figsize=(10, 6))


plt.scatter(X_test_scaled, y_test, color='blue', label='Datos Reales')
plt.scatter(X_test_scaled, y_test_pred, color='red', label='Predicciones del Modelo')


plt.xlabel('Celsius')
plt.ylabel('Valks')
plt.title('Predicciones vs Valores Reales')
plt.legend()
plt.show()

```

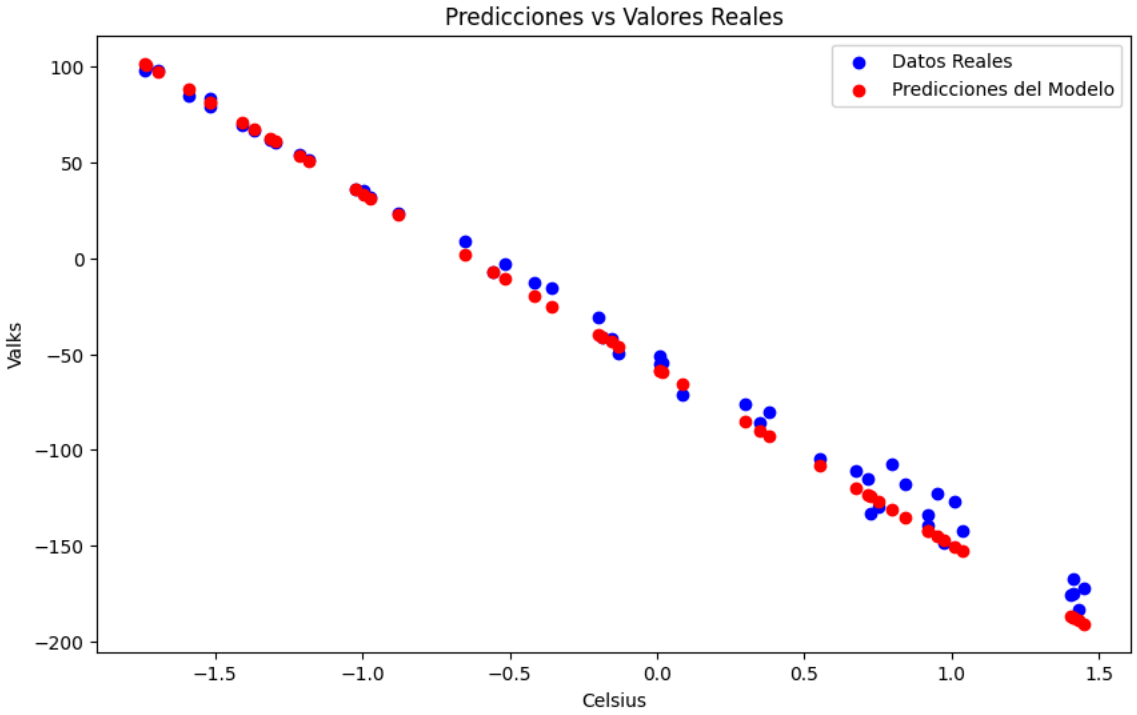
Predicciones vs Valores Reales
Datos Reales
Predicciones del Modelo
Valks
Celsius
100
50
0
−50
−100
−150
−200
−1.5
−1.0
−0.5
0.0
0.5
1.0
1.5