

# Componentes principales

Jacobo Hirsch Rodriguez

2024-10-09

#Lectura del dataset vamos a leer el dataset de las variables

```
corporal=read.csv("./corporal.csv") #leer el dataset  
print(corporal)
```

##	edad	peso	altura	sexo	muneca	biceps
## 1	43	87.3	188.0	Hombre	12.2	35.8
## 2	65	80.0	174.0	Hombre	12.0	35.0
## 3	45	82.3	176.5	Hombre	11.2	38.5
## 4	37	73.6	180.3	Hombre	11.2	32.2
## 5	55	74.1	167.6	Hombre	11.8	32.9
## 6	33	85.9	188.0	Hombre	12.4	38.5
## 7	25	73.2	180.3	Hombre	10.6	38.3
## 8	35	76.3	167.6	Hombre	11.3	35.0
## 9	28	65.9	183.0	Hombre	10.2	32.1
## 10	26	90.9	183.0	Hombre	12.0	40.4
## 11	43	89.1	179.1	Hombre	11.3	36.5
## 12	30	62.3	170.2	Hombre	11.5	34.2
## 13	26	82.7	177.8	Hombre	11.5	35.2
## 14	51	79.1	179.1	Hombre	11.8	34.0
## 15	30	98.2	190.5	Hombre	10.7	34.8
## 16	24	84.1	177.8	Hombre	11.5	38.6
## 17	35	83.2	180.3	Hombre	11.1	36.4
## 18	37	83.2	180.3	Hombre	10.5	34.0
## 19	22	51.6	161.2	Mujer	9.2	24.3
## 20	20	59.0	167.5	Mujer	9.9	27.8
## 21	19	49.2	159.5	Mujer	8.9	24.0
## 22	25	63.0	157.0	Mujer	9.5	28.0
## 23	21	53.6	155.8	Mujer	9.1	26.9
## 24	23	59.0	170.0	Mujer	10.0	26.5
## 25	26	47.6	159.1	Mujer	9.4	24.1
## 26	22	69.8	166.0	Mujer	10.7	29.2
## 27	28	66.8	176.2	Mujer	9.8	29.0
## 28	40	75.2	160.2	Mujer	11.5	33.6
## 29	32	55.2	172.5	Mujer	8.6	24.8
## 30	25	54.2	170.9	Mujer	9.7	25.4
## 31	25	62.5	172.9	Mujer	9.2	25.9
## 32	29	42.0	153.4	Mujer	8.3	24.0
## 33	22	50.0	160.0	Mujer	8.6	25.6
## 34	25	49.8	147.2	Mujer	9.0	26.0

```
## 35 23 49.2 168.2 Mujer 9.6 23.5
## 36 37 73.2 175.0 Mujer 11.0 31.0
```

#Análisis de las variables

```
summary(corporal)
```

```
##      edad      peso      altura      sexo
## Min.   :19.00  Min.   :42.00  Min.   :147.2  Length:36
## 1st Qu.:24.75  1st Qu.:54.95  1st Qu.:164.8  Class :character
## Median :28.00  Median :71.50  Median :172.7  Mode  :character
## Mean   :31.44  Mean   :68.95  Mean   :171.6
## 3rd Qu.:37.00  3rd Qu.:82.40  3rd Qu.:179.4
## Max.   :65.00  Max.   :98.20  Max.   :190.5
##      muneca      biceps
## Min.   : 8.300  Min.   :23.50
## 1st Qu.: 9.475  1st Qu.:25.98
## Median :10.650  Median :32.15
## Mean   :10.467  Mean   :31.17
## 3rd Qu.:11.500  3rd Qu.:35.05
## Max.   :12.400  Max.   :40.40
```

Para hacer el análisis vamos a eliminar la variable sexo

```
# Remover la variable constante (sexo)
corporal <- corporal[ , !(names(corporal) %in% "sexo")]
```

ahora vamos a obtener la desviacion estándar

```
sapply(corporal, sd)
```

```
##      edad      peso      altura      muneca      biceps
## 10.554469 14.868999 10.520170  1.175463  5.234392
```

#Parte I

se calcula la matriz de correlaciones

```
corr_matrix_corporal <- cor(corporal)
print(corr_matrix_corporal)
```

```
##      edad      peso      altura      muneca      biceps
## edad  1.0000000 0.5153847 0.3302211 0.6204942 0.4836702
## peso  0.5153847 1.0000000 0.7973737 0.8493361 0.9088813
## altura 0.3302211 0.7973737 1.0000000 0.6595849 0.7086144
## muneca 0.6204942 0.8493361 0.6595849 1.0000000 0.8777369
## biceps 0.4836702 0.9088813 0.7086144 0.8777369 1.0000000
```

obtenemos el cálculo de los eigenvalores y vectores para la matriz de correlacion

```
# Cálculo de valores y vectores propios
eigen_cor <- eigen(corr_matrix_corporal)
```

obtenemos los eigenvalores

```
print(eigen_cor$values) # Valores propios
```

```
## [1] 3.75749733 0.72585665 0.32032981 0.12461873 0.07169749
```

obtenemos los eigenvectores

```
print(eigen_cor$vectors) # Vectores propios
```

```
##           [,1]      [,2]      [,3]      [,4]      [,5]
## [1,] -0.3359310  0.8575601 -0.34913780 -0.1360111  0.1065123
## [2,] -0.4927066 -0.1647821  0.06924561 -0.5249533 -0.6706087
## [3,] -0.4222426 -0.4542223 -0.73394453  0.2070673  0.1839617
## [4,] -0.4821923  0.1082775  0.36690716  0.7551547 -0.2255818
## [5,] -0.4833139 -0.1392684  0.44722747 -0.3046138  0.6739511
```

calculamos la varianza explicada por cada componente

```
# Varianza total
total_variance_cor <- sum(eigen_cor$values)

# Proporción de varianza explicada
var_explained_cor <- eigen_cor$values / total_variance_cor
print(var_explained_cor)
```

```
## [1] 0.75149947 0.14517133 0.06406596 0.02492375 0.01433950
```

```
# Varianza acumulada
var_acum_cor <- cumsum(var_explained_cor)
print(var_acum_cor)
```

```
## [1] 0.7514995 0.8966708 0.9607368 0.9856605 1.0000000
```

De acuerdo a los resultados obtenidos podemos decir que los primeros 3 componentes explican arriba del 90% de los datos Vamos a obtener las ecuaciones de los 3 primeros componentes principales

```
# Obtenemos los nombres de las variables
variable_names <- colnames(corporal)

# Obtenemos los coeficientes de los vectores propios para CP1 , CP2 Y CP3
coef_CP1_cor <- eigen_cor$vectors[, 1] # Coeficientes de la primera componente principal
coef_CP2_cor <- eigen_cor$vectors[, 2] # Coeficientes del segundo componente principal
coef_CP3_cor <- eigen_cor$vectors[, 3] # Coeficientes del tercer componente principal

# Generamos las ecuaciones en formato LaTeX para CP1 , CP2 y CP3
```

```

latex_eq_CP1_cor <- paste0(
  "CP1 = ", paste(round(coef_CP1_cor, 4), variable_names, collapse = " + ")
)
latex_eq_CP2_cor <- paste0(
  "CP2 = ", paste(round(coef_CP2_cor, 4), variable_names, collapse = " + ")
)
latex_eq_CP3_cor <- paste0(
  "CP3 = ", paste(round(coef_CP3_cor, 4), variable_names, collapse = " + ")
)

```

*# Mostramos las ecuaciones en LaTeX*

```
cat("Ecuación de la primera componente principal (CP1):\n")
```

## Ecuación de la primera componente principal (CP1):

```
cat( latex_eq_CP1_cor, "\n")
```

## CP1 = -0.3359 edad + -0.4927 peso + -0.4222 altura + -0.4822 muneca + -0.4833 biceps

```
cat("Ecuación del segundo componente principal (CP2):\n")
```

## Ecuación del segundo componente principal (CP2):

```
cat( latex_eq_CP2_cor, "\n")
```

## CP2 = 0.8576 edad + -0.1648 peso + -0.4542 altura + 0.1083 muneca + -0.1393 biceps

```
cat("Ecuación del tercer componente principal (CP3):\n")
```

## Ecuación del tercer componente principal (CP3):

```
cat( latex_eq_CP3_cor, "\n")
```

## CP3 = -0.3491 edad + 0.0692 peso + -0.7339 altura + 0.3669 muneca + 0.4472 biceps

para saber que variable aporta más, debemos ver al valor absoluto de los coeficientes, el que sea el más alto por componente es el que más aporta: CP1: peso CP2: edad CP3: altura

también calculamos la matriz de varianza-covarianza

*# Matriz de varianza-covarianza*

```
cov_matrix_corporal <- cov(corporal)
print(cov_matrix_corporal)
```

```
##          edad      peso      altura      muneca      biceps
## edad    111.396825  80.88159  36.666032  7.698095  26.720952
## peso     80.881587 221.08713 124.728698 14.844667  70.738381
## altura   36.666032 124.72870 110.673968  8.156476  39.021048
## muneca    7.698095  14.84467   8.156476  1.381714  5.400571
## biceps   26.720952  70.73838  39.021048  5.400571  27.398857
```

cáculamos los valores y los vectores propios

```
eigen_cov <- eigen(cov_matrix_corporal)
```

obtenemos los eigenvalores

```
print(eigen_cov$values)
```

```
## [1] 359.3980243 80.3757858 27.6229011 4.3074318 0.2343571
```

obtenemos los eigenvectores

```
print(eigen_cov$vectors)
```

```
##           [,1]      [,2]      [,3]      [,4]      [,5]
## [1,] -0.34871002  0.9075501 -0.23248825 -0.001589466  0.026473941
## [2,] -0.76617586 -0.1616581  0.52166894 -0.338508602  0.010707863
## [3,] -0.47632405 -0.3851755 -0.78905759  0.046160807  0.003543154
## [4,] -0.05386189  0.0155423  0.02785902  0.126103480 -0.990039959
## [5,] -0.24817367 -0.0402221  0.22455005  0.931330496  0.137814357
```

La varianza explicada por cada componente principal se obtiene dividiendo cada valor propio entre la varianza total

```
# Varianza total
total_variance_cov <- sum(eigen_cov$values)

# Proporción de varianza explicada
var_explained_cov <- eigen_cov$values / total_variance_cov
print(var_explained_cov)
```

```
## [1] 0.7615357176 0.1703098726 0.0585307219 0.0091271040 0.0004965839
```

```
# Varianza acumulada
var_acum_cov <- cumsum(var_explained_cov)
print(var_acum_cov)
```

```
## [1] 0.7615357 0.9318456 0.9903763 0.9995034 1.0000000
```

para el caso en donde obtenemos los componentes principales utilizando la covarianza, podemos ver que con menos componentes obtenemos un resultado mayor a 90% ahora lo que vamos a hacer es obtener las ecuaciones

```
# Obtenemos los coeficientes de los vectores propios para CP1 y CP2
coef_CP1_cov <- eigen_cov$vectors[, 1] # Coeficientes de la primera componente principal
coef_CP2_cov <- eigen_cov$vectors[, 2] # Coeficientes de la segunda componente principal

# Generamos las ecuaciones en formato LaTeX para CP1 y CP2
latex_eq_CP1_cov <- paste0(
```

```

"CP1 = ", paste(round(coef_CP1_cov, 4), variable_names, collapse = " + ")
)
latex_eq_CP2_cov <- paste0(
  "CP2 = ", paste(round(coef_CP2_cov, 4), variable_names, collapse = " + ")
)

```

*# Mostramos las ecuaciones en LaTeX*

```
cat("Ecuación de la primera componente principal (CP1):\n")
```

## Ecuación de la primera componente principal (CP1):

```
cat( latex_eq_CP1_cov, "\n")
```

## CP1 = -0.3487 edad + -0.7662 peso + -0.4763 altura + -0.0539 muneca + -0.2482 biceps

```
cat("Ecuación del segundo componente principal (CP2):\n")
```

## Ecuación del segundo componente principal (CP2):

```
cat( latex_eq_CP2_cov, "\n")
```

## CP2 = 0.9076 edad + -0.1617 peso + -0.3852 altura + 0.0155 muneca + -0.0402 biceps

De igual forma vamos a obtener las variables que mas aporten información por componente:

CP1: Peso CP2: edad

para estos dos componentes podemos eliminar de una vez la variable sexo ya que no aporta ninguna información

#Parte II

*# Cargar los datos*

*# Asumimos que los datos están en el dataframe corporal\_data*

*# Análisis PCA con la matriz de varianzas-covarianzas (cor=FALSE)*

```
pca_cov <- princomp(corporal, cor = FALSE)
```

*# Análisis PCA con la matriz de correlaciones (cor=TRUE)*

```
pca_cor <- princomp(corporal, cor = TRUE)
```

*# Resumen de la varianza explicada para ambos análisis*

```
summary(pca_cov)
```

## Importance of components:

##	Comp.1	Comp.2	Comp.3	Comp.4	Comp.5
## Standard deviation	18.6926388	8.8398600	5.18223874	2.046406827	0.4773333561
## Proportion of Variance	0.7615357	0.1703099	0.05853072	0.009127104	0.0004965839
## Cumulative Proportion	0.7615357	0.9318456	0.99037631	0.999503416	1.0000000000

```
summary(pca_cor)
```

```
## Importance of components:
##               Comp.1   Comp.2   Comp.3   Comp.4   Comp.5
## Standard deviation   1.9384265 0.8519722 0.56597686 0.35301378 0.2677639
## Proportion of Variance 0.7514995 0.1451713 0.06406596 0.02492375 0.0143395
## Cumulative Proportion 0.7514995 0.8966708 0.96073676 0.98566050 1.0000000
```

Ahora vamos a calcular los scores:

Para la matriz de correlación

```
# Puntuaciones (scores) para la matriz de correlaciones
scores_cor <- as.matrix(corporal) %*% pca_cor$loadings
print(scores_cor)
```

```
##           Comp.1   Comp.2   Comp.3   Comp.4   Comp.5
## [1,] 160.0253 -66.56901 126.46234 14.4405421534 1.996033710
## [2,] 157.4245 -40.05091 124.80481 16.4069084892 6.165239686
## [3,] 154.2006 -59.29073 118.22588 16.0466831555 5.491792131
## [4,] 145.7863 -65.56626 121.64174 7.6855778324 6.927152615
## [5,] 147.3445 -44.47646 118.03729 12.7861454198 6.509172661
## [6,] 157.3776 -75.26829 121.78701 13.0169228408 3.644314535
## [7,] 144.2169 -76.70557 114.97184 8.1547002599 10.163699114
## [8,] 142.4837 -62.33679 110.14647 12.2380872649 4.431675752
## [9,] 139.5786 -73.33623 121.42597 2.5849488560 11.787112500
## [10,] 156.1038 -80.13193 114.62413 16.6057764041 -0.003383913
## [11,] 157.0586 -63.01798 119.82275 18.1212258068 -0.173531732
## [12,] 134.7138 -65.36555 111.56288 3.2755880398 13.181659802
## [13,] 147.1136 -75.74870 113.88447 12.1714944713 1.147252343
## [14,] 153.8518 -54.10737 124.24293 12.8206692502 5.586985423
## [15,] 160.8777 -80.67212 124.00122 18.7048395100 -6.573935440
## [16,] 148.7748 -78.16803 111.56868 13.6700938281 2.286809110
## [17,] 151.8261 -69.45904 118.43704 13.8080011458 3.129436771
## [18,] 151.0487 -67.47464 120.42880 13.8020430495 1.860327885
## [19,] 117.0603 -65.24514 108.17664 -2.8447166979 11.696142397
## [20,] 124.7238 -71.45289 109.76767 0.0009320151 9.880493270
## [21,] 113.8626 -66.64087 106.29195 -4.0254613668 12.538820836
## [22,] 123.8445 -63.12605 103.58728 5.3179919160 6.024044943
## [23,] 116.6381 -64.35239 102.59961 0.0548535119 11.029850420
## [24,] 126.2071 -69.82389 113.19465 -0.5802162935 9.761239820
## [25,] 115.5463 -60.15239 108.32496 -4.1775981391 14.238400382
## [26,] 131.1459 -70.94444 107.69753 6.0753868576 3.338067031
## [27,] 135.4596 -70.00740 117.90599 3.8232235231 7.933609591
## [28,] 139.9166 -54.28985 107.08988 13.2955016768 3.351942473
## [29,] 126.9171 -62.53007 119.70884 -1.3292343256 12.898165526
## [30,] 124.2177 -67.60591 115.48788 -3.1228595056 12.685080222
## [31,] 129.1522 -70.00581 116.34087 1.3500029547 7.936717508
## [32,] 110.8094 -54.17305 106.02498 -4.7288113936 17.445509370
## [33,] 116.1043 -64.68244 107.04545 -2.5870706178 13.559847772
## [34,] 111.9951 -56.27515 98.38657 0.1862168109 11.838144465
## [35,] 118.9757 -67.01693 114.04060 -5.9638174910 14.070453936
## [36,] 142.6749 -62.94750 118.38958 8.3585474725 5.456774242
```

Para la matriz de varianza-covarianza

```
# Puntuaciones (scores) para la matriz de varianzas-covarianzas
scores_cov <- as.matrix(corporal) %*% pca_cov$loadings
print(scores_cov)
```

```
##          Comp.1    Comp.2    Comp.3    Comp.4    Comp.5
## [1,] 180.9723 -48.75142 104.41935 -13.938178 -4.405445
## [2,] 176.1730 -22.18369 102.48068 -14.957786 -3.863033
## [3,] 172.9774 -41.82266  97.84009 -17.485181 -3.084644
## [4,] 163.7685 -48.88690 104.93178 -14.750951 -4.244360
## [5,] 164.5851 -27.75893  98.66081 -14.694438 -4.305027
## [6,] 177.0934 -57.70609 102.21295 -16.967798 -4.511084
## [7,] 160.7590 -59.96752 100.99755 -20.510882 -3.131639
## [8,] 159.7907 -46.35781  92.40574 -15.874250 -4.026518
## [9,] 155.9379 -56.86158 109.03701 -17.277170 -3.579251
## [10,] 176.5517 -63.02400  93.61640 -16.774663 -4.002715
## [11,] 178.2374 -45.65649  96.32562 -13.456469 -3.430198
## [12,] 148.3714 -49.59852 100.77228 -20.021492 -4.607846
## [13,] 166.4747 -59.49410  94.97257 -14.404427 -4.330559
## [14,] 172.7718 -36.67118 103.94967 -14.563565 -4.165041
## [15,] 185.6523 -63.25768  97.94980  -9.264013 -3.276787
## [16,] 167.6938 -61.67228  93.01379 -17.100218 -3.899947
## [17,] 171.4633 -52.42440  98.51846 -15.403425 -3.516688
## [18,] 171.5328 -50.52210  99.53907 -13.089391 -3.200471
## [19,] 130.5159 -51.30015  99.67984 -13.730593 -4.053370
## [20,] 139.3953 -56.86802  99.52015 -14.867550 -4.215435
## [21,] 126.7306 -52.97262  98.96870 -14.152078 -3.908846
## [22,] 139.2303 -48.94682  90.27704 -13.156705 -3.653858
## [23,] 129.7672 -50.55720  93.56206 -15.214746 -3.620240
## [24,] 141.3150 -55.05447 102.47939 -13.780065 -4.405318
## [25,] 127.8069 -46.20330 101.07879 -14.820286 -4.223317
## [26,] 148.0435 -56.26494  92.83086 -12.543983 -4.651249
## [27,] 152.5976 -54.26940 103.90916 -13.721053 -3.624916
## [28,] 156.8300 -38.73252  88.61179 -14.618430 -4.323095
## [29,] 142.2354 -47.18854 108.94750 -13.407688 -3.047113
## [30,] 138.4743 -52.77049 106.41389 -14.380977 -4.255163
## [31,] 145.8834 -54.91048 103.56381 -12.066291 -3.595274
## [32,] 121.7633 -40.39293 100.25307 -16.216203 -3.148793
## [33,] 129.0087 -50.64090  99.29244 -15.351881 -3.301572
## [34,] 123.9255 -42.96554  89.89334 -15.246930 -3.610534
## [35,] 132.1830 -52.66245 106.85623 -14.169927 -4.534060
## [36,] 160.6289 -46.73565 101.23348 -13.498885 -4.234791
```


Ahora vamos a graficar

para la matriz de varianza-covarianza

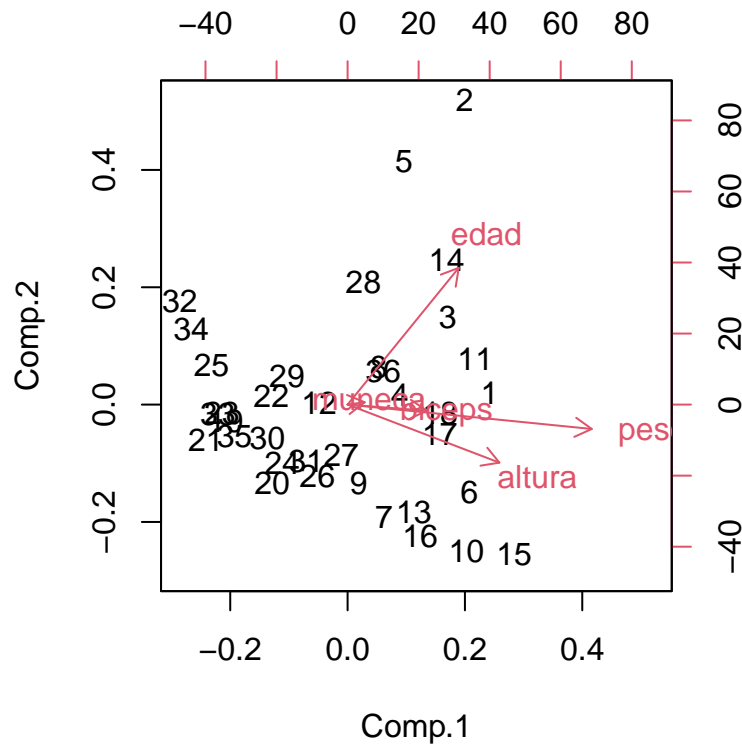
```
# Gráfico de las dos primeras componentes principales (varianza-covarianza)
plot(scores_cov[, 1:2], type = "p", main = "PCA con matriz de varianza-covarianza")
text(scores_cov[, 1], scores_cov[, 2], labels = 1:nrow(scores_cov))
```



## PCA con matriz de varianza-covarianza



```
biplot(pca_cov)
```




El primer componente principal (Comp.1) parece estar mayormente determinado por variables como el peso, la altura, la circunferencia de la muñeca y el tamaño del bíceps, lo que indica que este componente refleja principalmente la constitución física o el tamaño corporal de las personas. Por otro lado, el segundo componente principal (Comp.2) está influido sobre todo por la variable de la edad, lo que sugiere que este componente está más relacionado con la edad de los individuos.

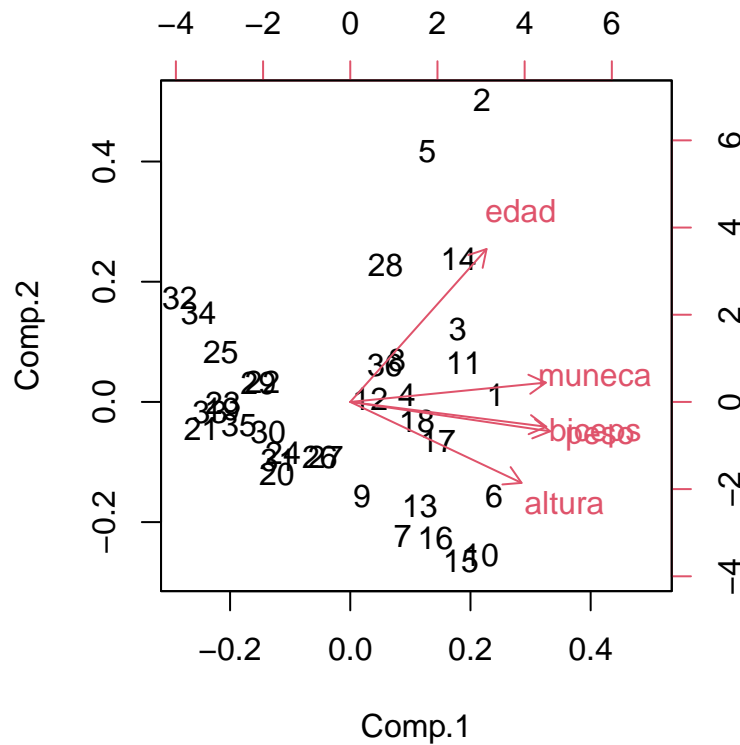
Para la matriz de correlacion

```
# Gráfico de las dos primeras componentes principales (correlación)
plot(scores_cor[, 1:2], type = "p", main = "PCA con matriz de correlaciones")
text(scores_cor[, 1], scores_cor[, 2], labels = 1:nrow(scores_cor))
```

## PCA con matriz de correlaciones



```
biplot(pca_cor)
```



asi como con el grafico anterior, parece ser que las medidas físicas corporales guardan como es de esperarse una relación a diferencia de la otra variable que no tiene la misma unidad, la edad.

#Parte III

graficas para la matriz de varianza-covarianza

```
# Cargar las librerías necesarias
library(FactoMineR)
library(factoextra)
```


```
## Loading required package: ggplot2
```


```
## Welcome! Want to learn more? See two factoextra-related books at https://goo.gl/ve3WBa
```

```
library(ggplot2)


# Cargar el dataset
# Asumimos que el dataset corporal ya está cargado en la variable corporal_data
# corporal_data <- read.csv("ruta/del/archivo.csv")

# PCA usando la matriz de varianza-covarianza
pca_cov <- PCA(corporal, scale.unit = FALSE)
```






```
# Gráfico de las observaciones (individuos)  
fviz_pca_ind(pca_cov, col.ind = "blue", addEllipses = TRUE, repel = TRUE)
```




```
# Gráfico de las variables
fviz_pca_var(pca_cov, col.var = "red", addEllipses = TRUE, repel = TRUE)
```

## Variables – PCA




```
# Scree plot para ver la proporción de varianza explicada por cada componente  
fviz_screepplot(pca_cov)
```

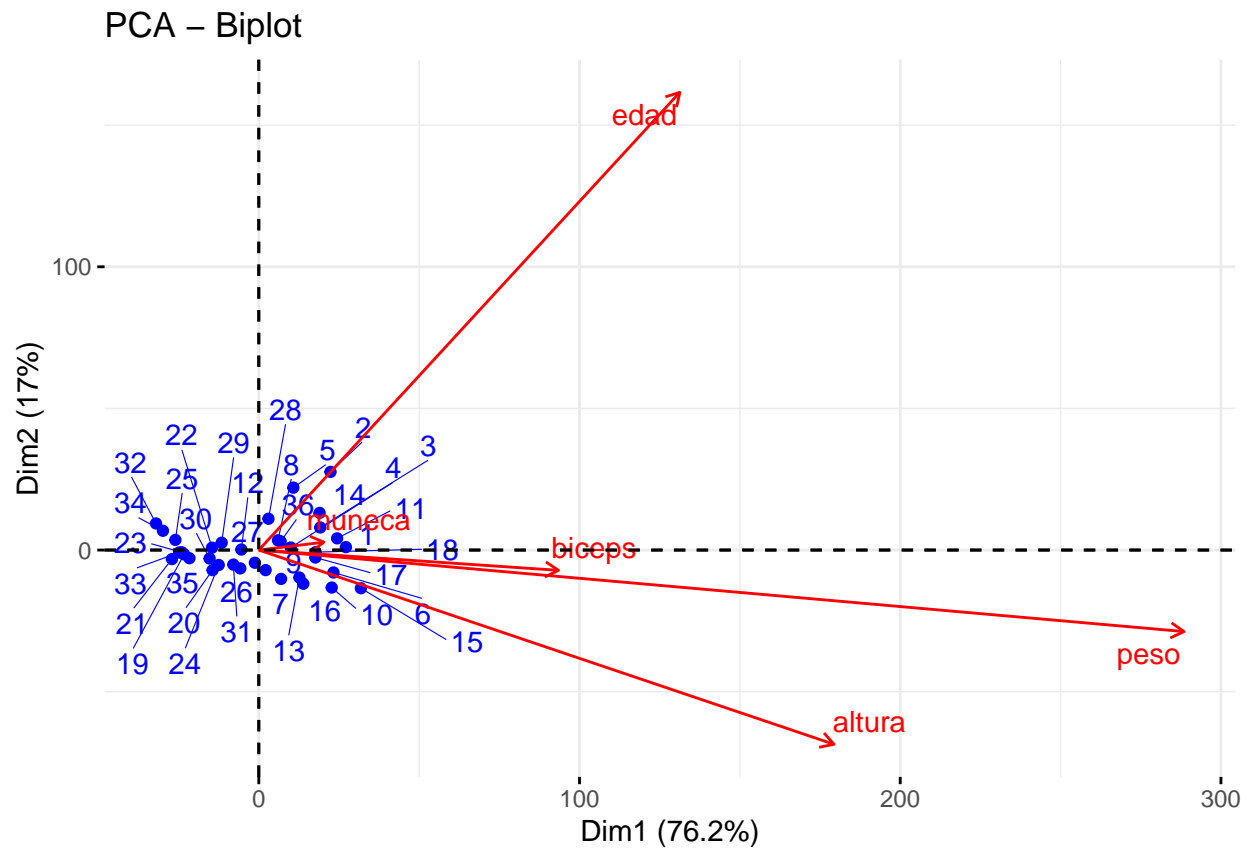




```
# Gráfico de contribución de las variables al PCA  
fviz_contrib(pca_cov, choice = "var")
```





```
# Biplot que incluye tanto las observaciones como las variables  
fviz_pca_biplot(pca_cov, repel = TRUE, col.var = "red", col.ind = "blue")
```



graficas para la matriz de correlación


```
# PCA usando la matriz de correlaciones
pca_cor <- PCA(corporal, scale.unit = TRUE)
```





```
# Gráfico de las observaciones (individuos)  
fviz_pca_ind(pca_cor, col.ind = "blue", addEllipses = TRUE, repel = TRUE)
```


## Individuals – PCA




```
# Gráfico de las variables
```

```
fviz_pca_var(pca_cor, col.var = "red", addEllipses = TRUE, repel = TRUE)
```

### Variables – PCA




```
# Scree plot para ver la proporción de varianza explicada por cada componente  
fviz_screepLOT(pca_cor)
```




```
# Gráfico de contribución de las variables al PCA  
fviz_contrib(pca_cor, choice = "var")
```





```
# Biplot que incluye tanto las observaciones como las variables  
fviz_pca_biplot(pca_cor, repel = TRUE, col.var = "red", col.ind = "blue")
```

## PCA – Biplot



#Parte IV

conclusiones:

En el análisis de componentes principales (PCA), tanto el enfoque estandarizado (basado en la matriz de correlaciones) como el no estandarizado (basado en la matriz de varianza-covarianza) muestran que el primer componente principal está dominado por las variables relacionadas con el tamaño corporal, como peso, altura, y bíceps, que están fuertemente correlacionadas entre sí. El segundo componente principal está más influenciado por la edad, que se comporta de manera independiente respecto a las otras medidas corporales. En general, el análisis estandarizado es más adecuado, ya que ajusta las variables a una escala comparable y evita que las variables con mayor varianza dominen el análisis, especialmente cuando las variables están en diferentes unidades.